

# 支持向量机与核算法

刘新旺 教授

<https://xinwangliu.github.io/>

国防科技大学 计算机学院  
计算科学系人工智能与大数据教研室

2020 年 10 月 13 日



- 1 线性分类
- 2 支持向量机
- 3 总结


## 分类：日常生活中的例子

- 信用卡申请Credit card application
- 垃圾邮件过滤
- 网络入侵检测
- ...

## 分类：日常生活中的例子

- 信用卡申请Credit card application
- 垃圾邮件过滤
- 网络入侵检测
- ...

## 示例



- $\mathcal{X} \subseteq \mathbb{R}^d$ : 输入空间
  - $\mathcal{Y} = \{-1, +1\}$ : 输出空间
  - $f: \mathcal{X} \mapsto \mathcal{Y}$ : 未知的目标函数
- 
- $\mathcal{S} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ , 其中  $y_i = f(\mathbf{x}_i)$ ,  $\{\mathbf{x}_i\}_{i=1}^n$  从输入空间  $\mathcal{X}$  中依据某个分布  $\mathcal{D}$  采集得到: 训练集合
  - $\mathcal{H} = \{\mathbf{x} \mapsto \text{sgn}(\boldsymbol{\omega}^\top \mathbf{x} + b) : \boldsymbol{\omega} \in \mathbb{R}^d, b \in \mathbb{R}\}$ : 假说集合
  - $R_{\mathcal{S}}(h) = \frac{1}{n} \sum_{i=1}^n [h(\mathbf{x}_i) \neq f(\mathbf{x}_i)]$  with  $h \in \mathcal{H}$ : 经验误差
  - $R_{\mathcal{D}}(h) = \Pr_{\mathbf{x} \sim \mathcal{D}} [h(\mathbf{x}) \neq f(\mathbf{x})]$  with  $h \in \mathcal{H}$ : 泛化误差

## 二分类问题形式化定义

给定训练样本集合  $\mathcal{S} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$ , 其中  $\{\mathbf{x}_i\}_{i=1}^n \subseteq \mathcal{X}^n$  独立同分布,  $y_i = f(\mathbf{x}_i) \in \mathcal{Y} (\forall i = 1, \dots, n)$ 。二分类问题的目标是基于数据  $\mathcal{S}$ , 从假说集合  $\mathcal{H}$  中选择一个假说  $h$ , 以使得 **期望误差**

$$E_{\mathbf{x} \sim \mathcal{D}} [h(\mathbf{x}) \neq f(\mathbf{x})] \quad (1)$$

最小。

## 二分类问题形式化定义


给定训练样本集合  $\mathcal{S} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$ , 其中  $\{\mathbf{x}_i\}_{i=1}^n \subseteq \mathcal{X}^n$  独立同分布,  $y_i = f(\mathbf{x}_i) \in \mathcal{Y} (\forall i = 1, \dots, n)$ 。二分类问题的目标是基于数据  $\mathcal{S}$ , 从假说集合  $\mathcal{H}$  中选择一个假说  $h$ , 以使得 **期望误差**

$$E_{\mathbf{x} \sim \mathcal{D}} [h(\mathbf{x}) \neq f(\mathbf{x})] \quad (1)$$

最小。

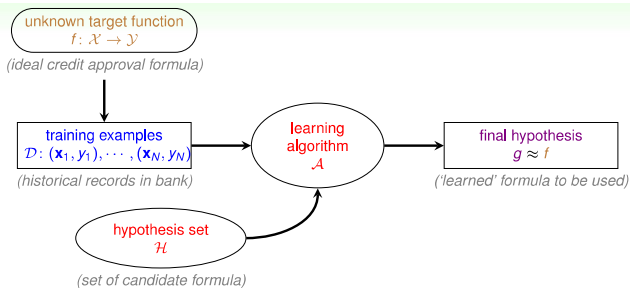
$$\begin{aligned} E_{\mathbf{x} \sim \mathcal{D}} [h(\mathbf{x}) \neq f(\mathbf{x})] &= 1 \cdot \Pr_{\mathbf{x} \sim \mathcal{D}}(h(\mathbf{x}) \neq f(\mathbf{x})) + 0 \cdot \Pr_{\mathbf{x} \sim \mathcal{D}}(h(\mathbf{x}) = f(\mathbf{x})) \\ &= \Pr_{\mathbf{x} \sim \mathcal{D}}(h(\mathbf{x}) \neq f(\mathbf{x})) \end{aligned} \quad (2)$$

# 学习一个分类器






# 学习一个分类器



## 假说集(线性)

$$\mathcal{H} = \{\mathbf{x} \mapsto \text{sgn}(\boldsymbol{\omega}^\top \mathbf{x} + b) : \boldsymbol{\omega} \in \mathbb{R}^d, b \in \mathbb{R}\}.$$

# 学习一个分类器



## 假说集(线性)

$$\mathcal{H} = \{\mathbf{x} \mapsto \text{sgn}(\boldsymbol{\omega}^\top \mathbf{x} + b) : \boldsymbol{\omega} \in \mathbb{R}^d, b \in \mathbb{R}\}.$$

## 学习算法

$\mathcal{A}$ : 支持向量机 (Support Vector Machines, SVMs)

## 假说集

$$\mathcal{H} = \{\mathbf{x} \mapsto \text{sgn}[\boldsymbol{\omega}^\top \mathbf{x} + b] : \boldsymbol{\omega} \in \mathbb{R}^d, b \in \mathbb{R}\}.$$

- 假说集  $h \in \mathcal{H} : \mathbf{x} \in \mathcal{X} \mapsto \{-1, +1\}$ .
- 决策函数  $h' : \mathbf{x} \in \mathcal{X} \mapsto \boldsymbol{\omega}^\top \mathbf{x} + b \in \mathbf{R}$ .
- $h(x) = \text{sgn}[h'(x)]$ 。因为假说  $h$  由  $h'$  确定,  $h'$  是我们研究关注的重点, 因此我们通常直接称它为分类器。
- 线性分类器:  $h'$  是线性的。

## 1 线性分类

## 2 支持向量机

线性可分


Non-Separable Case

实现

选择正则化参数 $C$

## 3 总结

# 线性分类算法



(a) 支持向量机

- 考虑超平面  $\omega^\top \mathbf{x} + b = 0$
- 给定  $a > 0$ , 我们要求该超平面
  - 对于正类样本(即  $y_i = 1$ )
$$\omega^\top \mathbf{x}_i + b \geq a$$
  - 对于负类样本(即  $y_i = -1$ )
$$\omega^\top \mathbf{x}_i + b \leq -a$$
  - 即  $y_i (\omega^\top \mathbf{x}_i + b) \geq a \forall i$

样本  $\mathbf{x}_i$  到超平面  $\omega^\top \mathbf{x} + b = 0$  的距离:  $\frac{|\omega^\top \mathbf{x}_i + b|}{\|\omega\|} = \frac{y_i (\omega^\top \mathbf{x}_i + b)}{\|\omega\|}$

样本集  $\mathcal{S}$  到超平面  $\omega^\top \mathbf{x} + b = 0$  的距离  $\rho$  被定义为:

$$\rho = \min_{(\mathbf{x}_i, y_i) \in \mathcal{S}} \frac{y_i (\omega^\top \mathbf{x}_i + b)}{\|\omega\|} = \frac{a}{\|\omega\|} \quad (3)$$

## 优化目标

$$\max_{\omega, b} \frac{a}{\|\omega\|} \quad s.t. \quad y_i \left( \omega^\top \mathbf{x}_i + b \right) \geq a, \forall i \quad (4)$$

## 优化目标

$$\max_{\omega, b} \frac{a}{\|\omega\|} \quad s.t. \quad y_i (\omega^\top \mathbf{x}_i + b) \geq a, \forall i \quad (4)$$

定义  $\hat{\omega} = \frac{\omega}{a}$  和  $\hat{b} = \frac{b}{a}$ , EQ.(4) 可以等价地写成

## 优化目标—等价形式

$$\max_{\hat{\omega}, \hat{b}} \frac{1}{\|\hat{\omega}\|} \quad s.t. \quad y_i (\hat{\omega}^\top \mathbf{x}_i + \hat{b}) \geq 1, \forall i \quad (5)$$

这种变换  $((\omega, b) \Rightarrow (\hat{\omega}, \hat{b}))$  会不会影响分类器的预测性能?

## 优化目标

$$\max_{\omega, b} \quad \frac{a}{\|\omega\|} \quad s.t. \quad y_i (\omega^\top \mathbf{x}_i + b) \geq a, \forall i \quad (4)$$

定义  $\hat{\omega} = \frac{\omega}{a}$  和  $\hat{b} = \frac{b}{a}$ , EQ.(4) 可以等价地写成

## 优化目标—等价形式

$$\max_{\hat{\omega}, \hat{b}} \quad \frac{1}{\|\hat{\omega}\|} \quad s.t. \quad y_i (\hat{\omega}^\top \mathbf{x}_i + \hat{b}) \geq 1, \forall i \quad (5)$$

这种变换  $((\omega, b) \Rightarrow (\hat{\omega}, \hat{b}))$  会不会影响分类器的预测性能?

$$h(\mathbf{x}) = \text{sgn}(\omega^\top \mathbf{x} + b) = \text{sgn}(a\hat{\omega}^\top \mathbf{x} + a\hat{b}) = \text{sgn}(\hat{\omega}^\top \mathbf{x} + \hat{b}) \triangleq \hat{h}(\mathbf{x}) \quad (a > 0)$$



## 优化目标—概念上等价

$$\begin{aligned} \min_{\hat{\omega}, \hat{b}} \quad & \frac{1}{2} \|\hat{\omega}\|^2 \\ \text{s.t.} \quad & y_i (\hat{\omega}^\top \mathbf{x}_i + \hat{b}) \geq 1, \forall i \end{aligned} \tag{6}$$

- 优化目标是严格正定的（Hessian矩阵）
- 所有的约束都是线性的
- EQ.(6)中的优化问题是具有线性约束的二次规划—典型的凸优化问题。
- 最优解存在且唯一

## Lagrange函数

$$\mathcal{L}(\hat{\omega}, \hat{b}; \alpha) = \frac{1}{2} \|\hat{\omega}\|^2 - \sum_{i=1}^n \alpha_i \left( y_i \left( \hat{\omega}^\top \mathbf{x}_i + \hat{b} \right) - 1 \right) \quad (7)$$

其中  $\alpha = [\alpha_1, \dots, \alpha_n]^\top$ ,  $\alpha_i \geq 0 (\forall i)$  为Lagrange乘子。

## KKT条件

$$\begin{cases} \nabla_{\hat{\omega}} \mathcal{L} = \hat{\omega} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i = 0 & \implies \hat{\omega} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \\ \nabla_{\hat{b}} \mathcal{L} = - \sum_{i=1}^n \alpha_i y_i = 0 & \implies \sum_{i=1}^n \alpha_i y_i = 0 \\ \forall i \quad \alpha_i \left( y_i \left( \hat{\omega}^\top \mathbf{x}_i + \hat{b} \right) - 1 \right) = 0 & \implies \alpha_i \vee y_i \left( \hat{\omega}^\top \mathbf{x}_i + \hat{b} \right) = 1 \end{cases} \quad (8)$$

## 对偶问题

$$\begin{aligned}
 \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (\mathbf{x}_i^\top \mathbf{x}_j) - \sum_{i=1}^n \alpha_i \\
 \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \alpha_i \geq 0, \forall i.
 \end{aligned} \tag{9}$$

上式是一个标准的带约束二次规划问题。

- 支持向量(Support Vectors): 对应 $\alpha_i \geq 0$  ( $\forall i$ )的样本
- 怎样计算 $\hat{b}$ ?

## 对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (\mathbf{x}_i^{\top} \mathbf{x}_j) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \alpha_i \geq 0, \forall i. \end{aligned} \tag{9}$$

上式是一个标准的带约束二次规划问题。

- 支持向量(Support Vectors): 对应 $\alpha_i \geq 0$  ( $\forall i$ )的样本
- 怎样计算 $\hat{b}$ ?  $\hat{b} = y_i - \sum_{j=1}^n \alpha_j y_j (\mathbf{x}_j^{\top} \mathbf{x}_i)$  ( $\alpha_i > 0$ )

## 对偶问题


$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (\mathbf{x}_i^{\top} \mathbf{x}_j) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \alpha_i \geq 0, \forall i. \end{aligned} \tag{9}$$

上式是一个标准的带约束二次规划问题。

- 支持向量(Support Vectors): 对应 $\alpha_i \geq 0$  ( $\forall i$ )的样本
- 怎样计算 $\hat{b}$ ?  $\hat{b} = y_i - \sum_{j=1}^n \alpha_j y_j (\mathbf{x}_j^{\top} \mathbf{x}_i)$  ( $\alpha_i > 0$ )
- 预测函数:  $\hat{h}(\mathbf{x}) = \text{sgn}(\hat{\omega}^{\top} \mathbf{x} + \hat{b}) = \text{sgn}(\sum_{j=1}^n \alpha_j y_j (\mathbf{x}_j^{\top} \mathbf{x}) + \hat{b})$
- 样本总是成对出现

- 在绝大多数应用中，训练数据并非线性可分，即对任意超平面  $\omega^\top \mathbf{x} + b = 0$ ，存在  $\mathbf{x}_i \in \mathcal{S}$ ，使得

$$y_i (\omega^\top \mathbf{x}_i + b) \not\geq 1 \quad (10)$$



超平面  $\omega^\top \mathbf{x} + b = 0$ : i) 错误地分类  $\mathbf{x}_i$ ; ii) 正确地分类  $\mathbf{x}_j$ ，但是间隔小于1

考虑如下两个相互矛盾的因素

- 间距最大化
- 训练误差最小化

考虑如下两个相互矛盾的因素

- 间距最大化
- 训练误差最小化

## 优化目标—松弛变量

$$\min_{\hat{\omega}, \hat{b}, \xi} \quad \frac{1}{2} \|\hat{\omega}\|^2 + C \sum_{i=1}^n \xi_i \quad s.t. \quad y_i (\hat{\omega}^\top \mathbf{x}_i + \hat{b}) \geq 1 - \xi_i, \xi_i \geq 0, \forall i \quad (11)$$

- 允许训练过程中有误差
- $C$ 为正则化参数—调节模型复杂度与训练误差



$$\begin{aligned} \mathcal{L}(\hat{\omega}, \hat{b}, \xi; \alpha, \beta) = & \frac{1}{2} \|\hat{\omega}\|^2 + C \sum_{i=1}^n \xi_i \\ & - \sum_{i=1}^n \alpha_i \left( y_i \left( \hat{\omega}^\top \mathbf{x}_i + \hat{b} \right) - 1 + \xi_i \right) - \sum_{i=1}^n \beta_i \xi_i \end{aligned} \quad (12)$$

其中  $\alpha = [\alpha_1, \dots, \alpha_n]^\top$ ,  $\beta = [\beta_1, \dots, \beta_n]^\top$  为Lagrange乘子。

## KKT条件

$$\begin{cases} \nabla_{\hat{\omega}} \mathcal{L} = \hat{\omega} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i = 0 & \implies \hat{\omega} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \\ \nabla_{\hat{b}} \mathcal{L} = - \sum_{i=1}^n \alpha_i y_i = 0 & \implies \sum_{i=1}^n \alpha_i y_i = 0 \\ \nabla_{\xi_i} \mathcal{L} = C - \alpha_i - \beta_i & \implies \alpha_i + \beta_i = C \\ \forall i \quad \alpha_i \left( y_i \left( \hat{\omega}^\top \mathbf{x}_i + \hat{b} \right) - 1 + \xi_i \right) = 0 & \implies \alpha_i \vee y_i \left( \hat{\omega}^\top \mathbf{x}_i + \hat{b} \right) = 1 - \xi_i \\ \forall i \quad \beta_i \xi_i = 0 & \implies \beta_i = 0 \vee \xi_i = 0 \end{cases} \quad (13)$$

## 对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \left( \mathbf{x}_i^\top \mathbf{x}_j \right) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \text{ } C \geq \alpha_i \geq 0, \forall i. \end{aligned} \tag{14}$$


```

function [w, d, pos, obj]=mySVMclass(y, c, X)

if min(y) ~= -1
    error(' y must coded: 1 for class one and -1 for class two')
end

%-----
%       monqp(H, b, c) solves the quadratic programming problem:
%
%       min 0.5*x'Hx - d'x    subject to:  A'x = b   and   0 <= x <= c
%       x
%-----
K = X*X';
KY = sparse(y*y');
H = K.*KY;
e = ones(size(y));
A = y;
b = 0;
[alpha, lambda0, pos] = mymonqp(H, e, A, b, c);
alphaall=zeros(size(e));
alphaall(pos)=alpha;
obj=-0.5*alphaall'*H*alphaall +e'*alphaall;
ysup = y(pos);
w = (alpha.*ysup);
d = lambda0;

```


[About](#) [Citation Policy](#)

### Welcome to the UC Irvine Machine Learning Repository!

We currently maintain 332 data sets as a service to the machine learning community. You may [view all data sets](#) through our searchable interface. Our [old web site](#) is still available, for those who prefer the old format. For a general overview of the Repository, please visit our [About page](#). For sets in publications, please read our [citation policy](#). If you wish to donate a data set, please consult our [donation policy](#). For any other questions, feel free to [contact the Repository librarians](#). We have also set up a [mirror site](#) for the Repository.

Supported By:



In Collaboration With:



#### Latest News:

2013-04-04: Welcome to the new Repository admins Kevin Bache and Moshe Lichman!  
 2010-03-01: [Note](#) from donor regarding Netflix data  
 2009-10-16: Two new data sets have been added.  
 2009-09-14: Several data sets have been added.  
 2008-07-23: [Repository mirror](#) has been set up.  
 2008-03-24: New data sets have been added!  
 2007-06-25: Two new data sets have been added: UJI Pen Characters, MAGIC Gamma Telescope

#### Featured Data Set: [MAGIC Gamma Telescope](#)



Task: Classification  
 Data Type: Multivariate  
 # Attributes: 11  
 # Instances: 19020

Data are MC generated to simulate registration of high energy gamma particles in an atmospheric Cherenkov telescope

#### Newest Data Sets:

- 2015-08-04: [Mice Protein Expression](#)
- 2015-07-29: [Smartphone-Based Recognition of Human Activities and Postural Transitions](#)
- 2015-07-27: [Cuff-Less Blood Pressure Estimation](#)
- 2015-07-11: [Taxi Service Trajectory - Prediction Challenge, ECML PKDD 2015](#)
- 2015-07-05: [Folio](#)
- 2015-07-03: [Chronic Kidney Disease](#)
- 2015-06-06: [Machine Learning based ZAlpha Ltd. Stock Recommendations 2012-2014](#)
- 2015-05-31: [Online News Popularity](#)
- 2015-05-30: [Sentiment Labelled Sentences](#)
- 2015-05-25: [Forest type mapping](#)
- 2015-05-19: [Online Video Characteristics and Transcoding Time Dataset](#)

#### Most Popular Data Sets (hits since 2007):

- 777104: [Ins](#)
- 544909: [Adult](#)
- 451584: [Wine](#)
- 381333: [Car Evaluation](#)
- 357649: [Breast Cancer Wisconsin \(Diagnostic\)](#)
- 299405: [Abalone](#)
- 262348: [Wine Quality](#)
- 254879: [Heart Disease](#)
- 241112: [Poker Hand](#)
- 222269: [Human Activity Recognition Using Smartphones](#)
- 208330: [Forest Fires](#)

# 留一法 (Leave-One-Out, LOO)

- Training set  $\mathcal{S} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$
- Approach: Repeatedly leave one example out for testing.

Train	Test
$\{(\mathbf{x}_2, y_2), (\mathbf{x}_3, y_3), \dots, (\mathbf{x}_n, y_n)\}$	$(\mathbf{x}_1, y_1)$
$\{(\mathbf{x}_1, y_1), (\mathbf{x}_3, y_3), \dots, (\mathbf{x}_n, y_n)\}$	$(\mathbf{x}_2, y_2)$
$\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)\}$	$(\mathbf{x}_3, y_3)$
$\dots$	$\dots$
$\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_{n-1}, y_{n-1})\}$	$(\mathbf{x}_n, y_n)$

- Performance Evaluation:  $\text{Err}_{loo}(\mathcal{A}, C) = \frac{1}{n} \sum_{i=1}^n [h_{\mathcal{S}-\{\mathbf{x}_i\}}(\mathbf{x}_i) \neq y_i]$

- 1 线性分类
- 2 支持向量机
- 3 总结

- 支持向量机推导
- 优化算法
- Matlab实现
- 参数选择

- 支持向量机推导
- 优化算法
- Matlab实现
- 参数选择

Homework 2: 实现线性支持向量机算法




# 支持向量机(线性)优缺点

## ① 优点:

- 算法简单、直观、可理解性强

## ② 缺点: 表达能力有限, 无法捕获数据间的非线性模式。

- 输入—输出不再是线性关系;
- 类与类之间不能通过线性边界来划分。



## ③ Next: Kernel Methods